

Esquema metodológico de `simulacion.R`

TFM — Interpolación espacio-temporal de NO_2 en Madrid con modelos INLA-SPDE

Documento explicativo del flujo, el fundamento matemático, la justificación de cada decisión y posibles mejoras. Nivel: Máster en Estadística.

0. Idea general y una precisión de nomenclatura

El script recorre **tres escalas temporales** del NO_2 (mensual, diaria, horaria) y, para cada una, ajusta y valida un modelo bayesiano jerárquico espacio-temporal **INLA-SPDE** con covariables meteorológicas y de tráfico. Objetivo doble: **seleccionar** covariables/estructura por escala y **validar** la capacidad predictiva dejando fuera un tramo temporal.

Precisión importante. El fichero se llama `simulacion.R` pero **no es una simulación Monte Carlo** (no genera datos con parámetros *verdaderos* conocidos para medir su recuperación). Es **validación cruzada temporal por holdout** sobre datos reales. Conviene nombrarlo así en la memoria. En §9 se propone añadir una simulación con verdad conocida.

1. Fundamento matemático del modelo

1.1 El modelo jerárquico bayesiano en tres niveles

Sea $y_i = \log(\text{NO}_2)$ observado en la estación s_i en el instante t_i , $i = 1, \dots, n$.

Nivel 1 — Verosimilitud (datos):

$$y_i \mid \eta_i, \theta \sim \mathcal{N}(\eta_i, \sigma_\varepsilon^2), \quad \sigma_\varepsilon^2 = 1/\tau_\varepsilon$$

donde τ_ε es la **precisión del ruido de observación (nugget)**. El predictor lineal es

$$\eta_i = \beta_0 + \sum_{k=1}^K \beta_k X_k(s_i, t_i) + u(s_i, t_i).$$

Nivel 2 — Campo latente gaussiano $\mathbf{x} = (\beta_0, \beta, \mathbf{w})$, con $\mathbf{w}$ los valores del campo espacial en los nodos de la malla:

$$\mathbf{x} \mid \theta \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}(\theta)^{-1}),$$

un **campo aleatorio markoviano gaussiano (GMRF)** con **matriz de precisión dispersa** $\mathbf{Q}$ (la inversa de la covarianza). La dispersión de $\mathbf{Q}$ es lo que hace viable la inferencia.

Nivel 3 — Hiperparámetros $\theta = (\kappa, \tau, \tau_\varepsilon, \rho)$ con priors $\pi(\theta)$.

1.2 El campo espacial: covarianza de Matérn

El campo continuo $u(s)$ es un **campo gaussiano estacionario e isótropo** con función de covarianza de **Matérn**:

$$\text{Cov}(u(s), u(s')) = \sigma^2 \frac{2^{1-\nu}}{\Gamma(\nu)} (\kappa \|s - s'\|)^\nu K_\nu(\kappa \|s - s'\|),$$

donde: - $\|s - s'\|$ = distancia euclídea (en km), - $\kappa > 0$ = **parámetro de escala** (inverso del rango), - $\nu > 0$ = **suavidad** del campo, - σ^2 = **varianza marginal**, - K_ν = función de Bessel modificada de segunda especie.

El **rango empírico** (distancia a la que la correlación cae a $\approx 0,13$) es

$$r = \frac{\sqrt{8\nu}}{\kappa}.$$

En el código se estima r en km (bloque B6.5) para interpretar “hasta dónde llega” la correlación espacial.

1.3 El truco SPDE: de campo continuo a GMRF disperso

Lindgren, Rue & Lindström (2011) demostraron que un campo de Matérn es la **solución estacionaria** de la ecuación diferencial parcial estocástica (SPDE):

$$(\kappa^2 - \Delta)^{\alpha/2} (\tau u(s)) = \mathcal{W}(s), \quad \alpha = \nu + d/2,$$

donde Δ es el **Laplaciano**, $\mathcal{W}$ un **ruido blanco gaussiano** y d la dimensión. En 2D ($d = 2$) con $\alpha = 2$ del código:

$$\alpha = 2 \implies \nu = \alpha - d/2 = 2 - 1 = 1.$$

Es decir, se ajusta una **Matérn de suavidad** $\nu = 1$.

Aproximación por elementos finitos. El campo se representa en una **mallla triangular** con funciones base ψ_j lineales a trozos (valen 1 en su nodo, 0 en los demás):

$$u(s) \approx \sum_{j=1}^m \psi_j(s) w_j, \quad \mathbf{w} = (w_1, \dots, w_m)^\top \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}^{-1}).$$

La precisión $\mathbf{Q}$ se construye a partir de dos matrices dispersas de la mallla: - la **matriz de masa** $\mathbf{C}$ con $C_{ij} = \int \psi_i(s) \psi_j(s) ds$, - la **matriz de rigidez** $\mathbf{G}$ con $G_{ij} = \int \nabla \psi_i(s) \cdot \nabla \psi_j(s) ds$.

Para $\alpha = 2$:

$$\mathbf{Q}(\kappa, \tau) = \tau^2 (\kappa^2 \mathbf{C} + \mathbf{G}) \mathbf{C}^{-1} (\kappa^2 \mathbf{C} + \mathbf{G}).$$

$\mathbf{Q}$ es **dispersa** (cada nodo solo se relaciona con sus vecinos en la mallla), lo que permite factorizaciones de Cholesky rápidas — la clave computacional del método.

1.4 Matriz de proyección A

Las observaciones no están en los nodos, sino en las 24 estaciones. La **matriz de proyección A** ($n \times m$) evalúa las funciones base en las localizaciones:

$$A_{ij} = \psi_j(s_i), \quad u(s_i) = (\mathbf{A}\mathbf{w})_i.$$

El predictor lineal en forma matricial es $\eta = \mathbf{X}\beta + \mathbf{A}\mathbf{w}$. En INLA esto se ensambla con `inla.stack`.

1.5 Extensión espacio-temporal: AR1 separable (Bloque B4)

El campo se replica en cada instante t y los campos consecutivos se enlazan con un proceso **autor-regresivo de orden 1**:

$$w(s, t) = \rho w(s, t-1) + \xi(s, t), \quad |\rho| < 1,$$

siendo $\xi(\cdot, t)$ campos espaciales de Matérn independientes. Esto genera una **covarianza separable (producto de Kronecker)** espacio *times* tiempo. La precisión conjunta es

$$\mathbf{Q}_{st} = \mathbf{Q}_{\text{AR1}}(\rho) \otimes \mathbf{Q}_{\text{esp}}(\kappa, \tau),$$

donde la precisión del AR1 para T instantes es la tridiagonal

$$\mathbf{Q}_{\text{AR1}}(\rho) = \frac{1}{1 - \rho^2} \begin{pmatrix} 1 & -\rho & & & \\ -\rho & 1 + \rho^2 & -\rho & & \\ & \ddots & \ddots & \ddots & \\ & & -\rho & 1 + \rho^2 & -\rho \\ & & & -\rho & 1 \end{pmatrix}.$$

Consecuencia práctica (memoria): el campo latente tiene dimensión $m \times T$ (nodos *times* instantes). A escala horaria esto crece muy rápido (p. ej. $304 \times 120 \approx 36.500$ parámetros para 5 días), y factorizar $\mathbf{Q}_{st}$ es lo que consume RAM.

1.6 Inferencia: INLA

Se busca la marginal posterior de cada componente latente,

$$\pi(x_i | \mathbf{y}) = \int \pi(x_i | \theta, \mathbf{y}) \pi(\theta | \mathbf{y}) d\theta.$$

INLA (Rue, Martino & Chopin, 2009) aproxima esto **sin MCMC** mediante **aproximaciones de Laplace anidadas**:

1. Aproxima la posterior de los hiperparámetros:

$$\tilde{\pi}(\theta | \mathbf{y}) \propto \frac{\pi(\mathbf{x}, \theta, \mathbf{y})}{\tilde{\pi}_G(\mathbf{x} | \theta, \mathbf{y})} \Big|_{\mathbf{x}=\mathbf{x}^*(\theta)},$$

con $\tilde{\pi}_G$ la aproximación gaussiana en la moda $\mathbf{x}^*$.

2. Aproxima $\pi(x_i | \theta, \mathbf{y})$ (estrategia *gaussian*, *simplified laplace* o *laplace*).
3. **Integra numéricamente** sobre una rejilla de θ .

Es determinista, rápido y sin diagnósticos de convergencia de cadenas: el estándar para GMRF de gran dimensión.

2. Configuración — los “mandos”

Elemento	Valor	Fundamento
VIF_UMBRAL	5	Factor de inflación de varianza. Se descarta X_k si $VIF_k > 5$ (criterio conservador).
DIC_MEJORA_MIN	2	$\Delta DIC < 2$ se considera no informativo (regla estándar de comparación de modelos).
config_mallas	4 mallas (12/8/4/1 km)	El resultado del SPDE depende de la discretización; comparar resoluciones elige el equilibrio sesgo–coste con criterio empírico.
COVS_*	8 (mensual) / 4 (diario, horario)	Más covariables donde la agregación reduce ruido y colinealidad (macro); menos donde interesa el corto plazo (micro).

Factor de inflación de la varianza:

$$VIF_k = \frac{1}{1 - R_k^2},$$

donde R_k^2 es el coeficiente de determinación de regresar X_k sobre las demás covariables. Mide cuánto se infla $\text{Var}(\hat{\beta}_k)$ por colinealidad.

3. Preparación de datos (Bloque B0)

Cada escala carga su dataset y produce respuesta, covariables **estandarizadas** $\tilde{X}_k = (X_k - \bar{X}_k)/s_{X_k}$, coordenadas UTM en km, índice temporal `ID_TIEMPO_SIM` e indicador `es_train`.

Escala	Ventana	Train / Test
Mensual	2019–2025 (usa 2022+)	Train 2022–24, Test 2025
Diario	35 días (invierno/verano)	Test = últimos 7 días
Horario	5 días (invierno)	Train 4 días, Test 1 día

Escala	Ventana	Train / Test
Horario-perfil	perfil laborable/finde por mes (ene-sep)	Train meses 1–7, Test 8–9

Por qué holdout temporal (no aleatorio ni k-fold): con autocorrelación temporal, un *split* aleatorio filtra información del futuro (fuga de datos). Dejar fuera el **tramo final** imita predecir un periodo no observado y estima honestamente el error de generalización.

Por qué log(NO₂): la distribución cruda es asimétrica (asimetría $\approx 0,88$); el logaritmo la simetriza (≈ 0) y estabiliza la varianza, requisito de la verosimilitud gaussiana. Formalmente, si $\text{NO}_2 \sim \text{lognormal}$, entonces $\log(\text{NO}_2)$ es gaussiana.

Por qué estandarizar: deja $\hat{\beta}_k$ en “efecto por desviación típica”, comparables entre sí, y mejora el condicionamiento numérico.

4. Selección de covariables (Bloques B0.5 y B1)

4.1 B0.5 — Residuos parciales (ordenación por importancia)

Iterativo. Partiendo de $r^{(0)} = y$, en el paso m :

1. Para cada covariable candidata j se ajusta un SPDE univariante y se obtiene $\hat{\beta}_j$.
2. Se elige

$$j^* = \arg \min_j \text{sd}(r^{(m-1)} - \hat{\beta}_j X_j).$$

3. Se actualiza el residuo:

$$r^{(m)} = r^{(m-1)} - \hat{\beta}_{j^*} X_{j^*}.$$

Por qué dentro de un SPDE y no OLS: al estimar $\hat{\beta}_j$ con el campo espacial presente, los coeficientes están corregidos de **confusión espacial** (dos covariables con patrón espacial similar no se roban el efecto mutuamente).

4.2 B1 — Selección formal (tres filtros)

1. **VIF hacia atrás** (elimina colinealidad; $\text{VIF} > 5$).
2. **Significancia bayesiana:** se retiene X_k si su IC 95 % excluye 0,

$$0 \notin [q_{0,025}(\beta_k), q_{0,975}(\beta_k)].$$

3. **Stepwise por DIC:** se añade/quita la variable que más reduce el DIC mientras $\Delta\text{DIC} \geq 2$.

5. Ajuste y evaluación (Bloques B2 y B4)

B2 ajusta el modelo solo-espacial en las 4 mallas; **B4** el AR1, solo si B3 lo justifica. Sobre el **test** no visto se calculan, con $\hat{y}_i$ la predicción posterior media y $\hat{\sigma}_i$ su desviación:

$$\text{RMSE} = \sqrt{\frac{1}{n_{\text{test}}} \sum_i (\hat{y}_i - y_i)^2}, \quad \text{MAE} = \frac{1}{n_{\text{test}}} \sum_i |\hat{y}_i - y_i|,$$

$$\text{Cobertura}_{95} = \frac{1}{n_{\text{test}}} \sum_i \mathbf{1}\{y_i \in [\hat{y}_i \pm 1,96 \hat{\sigma}_i]\}.$$

Por qué la cobertura: RMSE mide el error del punto, pero un modelo bayesiano debe calibrar la **incertidumbre**; la cobertura debería aproximarse a 0,95. Es una comprobación que los modelos puramente predictivos suelen omitir.

Criterios de información (dentro de muestra).

$$\text{DIC} = \bar{D} + p_D, \quad \bar{D} = \mathbb{E}_{\mathbf{x}|\mathbf{y}}[D(\mathbf{x})], \quad p_D = \bar{D} - D(\bar{\mathbf{x}}), \quad D(\mathbf{x}) = -2 \log p(\mathbf{y} | \mathbf{x}),$$

$$\text{WAIC} = -2(\text{lppd} - p_{\text{WAIC}}), \quad \text{lppd} = \sum_i \log \mathbb{E}[p(y_i | \mathbf{x})], \quad p_{\text{WAIC}} = \sum_i \text{Var}[\log p(y_i | \mathbf{x})].$$

p_D y p_{WAIC} son el **número efectivo de parámetros** (penalización por complejidad). El WAIC es preferible por usar toda la posterior predictiva.

CPO (validación *leave-one-out* interna):

$$\text{CPO}_i = \pi(y_i | \mathbf{y}_{-i}), \quad \text{LPML} = \sum_i \log \text{CPO}_i.$$

Valores bajos de CPO_i señalan observaciones influyentes o mal predichas.

Parámetros físicos del campo (bloque B6.5): rango $r = \sqrt{8\nu}/\kappa$ y varianza marginal σ^2 , obtenidos de la posterior de los hiperparámetros vía `inla.spde.result`.

6. Diagnóstico de residuos y “gate” del AR1 (Bloques B3, B5)

Sobre los residuos se calcula la **función de autocorrelación** y el contraste de **Ljung–Box** a L retardos:

$$\hat{\rho}_k = \frac{\sum_t (r_t - \bar{r})(r_{t-k} - \bar{r})}{\sum_t (r_t - \bar{r})^2}, \quad Q_{LB} = n(n+2) \sum_{k=1}^L \frac{\hat{\rho}_k^2}{n-k} \sim \chi_L^2.$$

Si Q_{LB} es significativo (queda autocorrelación temporal) *rightarrow* **se activa el AR1 (B4)**. El Q-Q plot comprueba la normalidad de los residuos.

Por qué este *gate*: parsimonia — no se añade la complejidad temporal salvo que los datos la exijan. **Matiz crítico:** el test se aplica sobre la *media espacial* de los residuos por instante, lo que **pierde potencia**; un diagnóstico intra-estación (ver §9) da $\hat{\rho}_1 \approx 0,81$, es decir, el AR1 sí está justificado a nivel horario.

7. Comparación, interpretación y recuperación (Bloques B6–B7)

- **B6:** tabla y gráficos de RMSE/DIC/WAIC/tiempo *rightarrow* se elige el modelo de menor RMSE.
- **B6.5:** tablas de efectos fijos (con IC), hiperparámetros y parámetros físicos del SPDE.
- **B6b:** compara efectos entre el modelo espacial y el AR1 (¿alguna covariable era un artefacto de no modelar el tiempo?).
- **B7 — Tiempo de recuperación.** En un AR1, $\text{corr}(t, t+k) = \rho^k$. El tiempo de *decorrelación* τ (caída a $1/e$) cumple $\rho^\tau = e^{-1}$, de donde

$$\tau = -\frac{1}{\ln \rho}$$

Interpretación: n° de periodos que tarda un episodio de contaminación en “olvidarse”. Útil para gestión de calidad del aire.

Clasificación MACRO vs MICRO: cruzando la importancia de cada covariable entre escalas se etiqueta como **macro** (significativa a escala mensual *rightarrow* estacional/interanual) o **micro** (solo diaria/horaria *rightarrow* corto plazo). Es la síntesis que responde a la pregunta científica del TFM.

8. Limitaciones conocidas (para anticipar al tribunal)

1. “Simulación” = validación por holdout, no Monte Carlo con verdad conocida (§0, §9.1).
2. **Inestabilidad numérica horaria.** El modelo solo-espacial (B0.5/B2) amontona miles de observaciones horarias sobre 24 puntos en un único campo estático; el sistema queda **mal condicionado** (no separa campo de nugget) y el solver **se cae** por encima de ~4.600 observaciones.
3. **Potencia del *gate* AR1** (test sobre la media espacial): el AR1 casi nunca se dispara pese a que sí es necesario.
4. **Holdout único *rightarrow* RMSE** sin intervalo de confianza.
5. **Priors por defecto** en `inla.spde2.matern`.

9. Posibles mejoras (ordenadas por impacto)

9.1 Añadir un estudio de simulación real (recuperación de parámetros)

Generar un campo con **verdad conocida** $(\kappa_0, \tau_0, \rho_0, \beta_0)$:

$$\mathbf{w}^{\text{true}} \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}(\kappa_0, \tau_0)^{-1}) \text{ (inla.qsample)}, \quad y_i = \mathbf{x}_i^\top \beta_0 + (\mathbf{A}\mathbf{w}^{\text{true}})_i + \varepsilon_i,$$

ajustar el modelo y medir **sesgo** $\mathbb{E}[\hat{\theta}] - \theta_0$ y **cobertura** de los IC, repetido en R réplicas. Responde: ¿con 24 estaciones el SPDE recupera bien el rango?

9.2 Resolver el crash horario con AR1 desde el inicio

Sustituir el solo-espacial por la estructura espacio-temporal desde B0.5/B2 (evita el mal condicionamiento), o trabajar sobre el **perfil laborable/finde** (reduce ~10.000 a ~430 filas).

9.3 Diagnóstico intra-estación + descomposición de varianza

Sustituir el Ljung-Box sobre la media espacial por **ACF por estación**. Prueba realizada: $\hat{\rho}_1 = 0,81$, las 24 estaciones rechazan ruido blanco. Descomponer además

$$\text{Var}(y) \approx \underbrace{\text{Var}(\mathbf{X}\beta)}_{\text{covariables}} + \underbrace{\sigma_{\text{esp}}^2}_{\text{campo}} + \underbrace{\sigma_{\varepsilon}^2}_{\text{nugget}}.$$

(En enero salió *approx* 47 % / 11 % / 42 %.)

9.4 Selección por tamaño de efecto a nivel horario

Con $N \approx 17.500$ todo es significativo; usar un umbral de $|\hat{\beta}_{\text{estand.}}|$ para distinguir lo relevante de lo despreciable.

9.5 Priors de Complejidad Penalizada (PC-priors)

Con `inla.spde2.pcmatern`, priors de la forma

$$P(r < r_0) = \alpha_r, \quad P(\sigma > \sigma_0) = \alpha_\sigma,$$

que penalizan la desviación respecto a un modelo base, regularizan y evitan que τ_ε diverja (una causa del crash).

9.6 Predecir fuera del *stack* de estimación

Ajustar solo con las observaciones y proyectar después con `inla.mesh.projector`; reduce mucho la memoria del AR1.

9.7 Validación con réplicas (*rolling-origin*)

Repetir el holdout con varios orígenes temporales para dar **IC del RMSE**.

9.8 Modo compacto / PARDISO

`inla.setOption(inla.mode="compact")` y el solver PARDISO aceleran y ahorran memoria.

9.9 Covariables retardadas (resultado negativo, probado)

Añadir tráfico en $h-1$ **no** resultó significativo una vez incluido el contemporáneo (colineales entre sí). La persistencia del NO_2 no viene de la memoria del tráfico, sino del proceso atmosférico *rightarrow* se modela con **AR1**, no con retardos.

10. Referencias

- Lindgren, F., Rue, H., Lindström, J. (2011). *An explicit link between Gaussian fields and Gaussian Markov random fields: the SPDE approach*. JRSS-B, 73(4), 423–498.
- Rue, H., Martino, S., Chopin, N. (2009). *Approximate Bayesian inference for latent Gaussian models using integrated nested Laplace approximations*. JRSS-B, 71(2), 319–392.
- Krainski, E. T. et al. (2019). *Advanced Spatial Modeling with Stochastic Partial Differential Equations using R and INLA*. Chapman & Hall/CRC.

- Blangiardo, M., Cameletti, M. (2015). *Spatial and Spatio-temporal Bayesian Models with R-INLA*. Wiley.
- Simpson, D. et al. (2017). *Penalising model component complexity: A principled, practical approach to constructing priors (PC-priors)*. Statistical Science, 32(1), 1–28.
- Watanabe, S. (2010). *Asymptotic equivalence of Bayes cross validation and WAIC*. JMLR, 11.